


UJIAN TENGAH SEMESTER
BIG DATA PREDICTIVE



Disusun Oleh :
Luthfiah Choirun Nisa
23.01.5107

PROGRAM STUDI TEKNIK INFORMATIKA
FAKULTAS ILMU KOMPUTER
UNIVERSITAS AMIKOM YOGYAKARTA
2025

1. Jelaskan apa yang dimaksud dengan Big Data dan sebutkan empat karakteristik utamanya?

Jawab :

- a. **Big Data** adalah sekumpulan data dalam jumlah yang sangat besar, kompleks, dan terus bertambah dengan cepat, sehingga tidak dapat diolah menggunakan metode pemrosesan data tradisional. Big Data biasanya berasal dari berbagai sumber seperti media sosial, sensor, transaksi keuangan, rekaman telepon, dan sebagainya.
- b. Empat karakteristik utama
 - **Volum** : Merujuk pada jumlah data yang sangat besar, bisa mencapai terabyte hingga petabyte bahkan exabyte.
 - **Velocity** : kecepatan aliran data yang tinggi dan pengumpulan data yang sangat cepat sehingga diproses hampir secara real-time.
 - **Variety** : Bentuk data yang beragam, tidak hanya data terstruktur (tabel), tetapi juga semi-terstruktur dan tidak terstruktur seperti gambar, video, teks, audio, log sistem, dan sebagainya.
 - **Veracity** : Menunjukkan tingkat kebenaran atau keakuratan data. Karena datanya sangat banyak dan beragam, sering ada data yang tidak konsisten, tidak akurat, atau tidak lengkap.

2. Berikan contoh penerapan Big Data Predictive dalam bidang bisnis atau teknologi yang kamu ketahui?

Jawab :

- a. E-commerce (seperti Amazon dan Tokopedia) menggunakan Big Data Predictive untuk menganalisis perilaku konsumen dan membangun sistem rekomendasi produk berbasis machine learning, yang bisa meningkatkan pendapatan dengan menawarkan produk yang relevan kepada pelanggan. Tokopedia juga menggunakan data untuk menentukan harga dinamis dan promosi yang disesuaikan dengan minat konsumen.
- b. Manufaktur memanfaatkan Big Data Predictive untuk predictive maintenance, yaitu memantau performa mesin dengan sensor IoT agar bisa memprediksi kapan mesin membutuhkan perawatan sehingga menghindari kerugian akibat downtime produksi.
- c. Transportasi dan logistik (seperti Gojek dan Grab) menggunakan Big Data Predictive untuk mengoptimalkan rute dan waktu tempuh, serta sistem dynamic pricing yang menyesuaikan harga berdasarkan permintaan lokal secara real-time.
- d. Retail dan bisnis ritel menggunakan data untuk memprediksi tren penjualan, permintaan produk, dan perilaku pelanggan sehingga bisa mengatur stok dan promosi secara lebih efektif.

3. Diberikan dataset sederhana dengan kolom berikut:

["Nama", "Usia", "Pendapatan", "Status"]

Sebagian data memiliki nilai kosong (missing value) dan ada duplikasi baris.

Jawab :

- Memasukan data ke python menggunakan pandas.

```
[5]: import pandas as pd

data = {
    "Nama": ["Andi", "Budi", "Citra", "Andi", "Dedi", "Erlina"],
    "Usia": [25, 30, 28, 25, None, 26],
    "Pendapatan": [5000000, 6000000, None, 5000000, 7000000, None],
    "Status": ["Aktif", "Aktif", "Tidak Aktif", "Aktif", "Aktif", "Aktif"]
}

df = pd.DataFrame(data)

print("=== DATA AWAL ===")
print(df)

=== DATA AWAL ===
   Nama  Usia  Pendapatan  Status
0  Andi   25.0    5000000.0    Aktif
1  Budi   30.0    6000000.0    Aktif
2  Citra  28.0         NaN  Tidak Aktif
3  Andi   25.0    5000000.0    Aktif
4  Dedi   NaN     7000000.0    Aktif
5  Erlina 26.0         NaN    Aktif
```

a. Jelaskan langkah-langkah yang kamu lakukan untuk membersihkan data tersebut.

- Import dataset ke python menggunakan pandas.
- Menampilkan data awal untuk melihat kondisi data sebelum di bersihkan.
- Menghapus barisan yang terduplikat menggunakan **drop_duplicates()** untuk memastikan setiap baris unik.
- Mengatasi missing value (nilai kosong) pada kolom numerik seperti pendapatan, nilai kosong bisa diganti dengan mean (rata-rata).
- Menampilkan data akhir agar terlihat perbedaan sebelum dan sesudah di bersihkan.

b. Tuliskan contoh potongan kode Python untuk menghapus duplikasi dan mengganti nilai kosong dengan rata-rata pendapatan.

- Untuk membersihkan data yang terduplikat menggunakan **drop_duplicates** untuk menghapus barisan yang sama.

```

5 Erlina 26.0 NaN Aktif
[6]: df = df.drop_duplicates()

print("\n=== DATA SETELAH MENGHAPUS DUPLIKAT ===")
print(df)

```

```

=== DATA SETELAH MENGHAPUS DUPLIKAT ===
   Nama  Usia  Pendapatan  Status
0  Andi  25.0  5000000.0   Aktif
1  Budi  30.0  6000000.0   Aktif
2  Citra  28.0      NaN  Tidak Aktif
4  Dedi   NaN  7000000.0   Aktif
5  Erlina 26.0      NaN   Aktif

```

- Kolom pendapatan ada nilai kosong, data tersebut data numerik maka di isi dengan mean

```

[7]: rata_pendapatan = df["Pendapatan"].mean()
df["Pendapatan"] = df["Pendapatan"].fillna(rata_pendapatan)

print("\n=== DATA SETELAH MENGISI NILAI KOSONG PENDAPATAN ===")
print(df)

```

```

=== DATA SETELAH MENGISI NILAI KOSONG PENDAPATAN ===
   Nama  Usia  Pendapatan  Status
0  Andi  25.0  5000000.0   Aktif
1  Budi  30.0  6000000.0   Aktif
2  Citra  28.0  6000000.0  Tidak Aktif
4  Dedi   NaN  7000000.0   Aktif
5  Erlina 26.0  6000000.0   Aktif

```

- Kolom usia juga punya nilai kosong maka dengan rata-rata tetep representative.

```

[10]: rata_usia = df["Usia"].mean()
df["Usia"] = df["Usia"].fillna(rata_usia)

print("\n=== DATA SETELAH MENGISI NILAI KOSONG USIA ===")
print(df)

```

```

=== DATA SETELAH MENGISI NILAI KOSONG USIA ===
   Nama  Usia  Pendapatan  Status
0  Andi  25.00  5000000.0   Aktif
1  Budi  30.00  6000000.0   Aktif
2  Citra  28.00  6000000.0  Tidak Aktif
4  Dedi  27.25  7000000.0   Aktif
5  Erlina 26.00  6000000.0   Aktif

```

- Maka proses pembersihan data sudah berhasil seperti duplikat sudah hilang, missing value sudah tersisi, dan dataset sudah bersih.

```
[11]: print("\n=== DATA BERSIH AKHIR ===")
      print(df)
```

```
=== DATA BERSIH AKHIR ===
   Nama  Usia  Pendapatan  Status
0  Andi  25.00  5000000.0   Aktif
1  Budi  30.00  6000000.0   Aktif
2  Citra  28.00  6000000.0  Tidak Aktif
4  Dedi  27.25  7000000.0   Aktif
5  Erlina  26.00  6000000.0   Aktif
```

4. Apa tujuan dari regresi linier sederhana dalam analisis data?

Jawab :

Tujuan utama regresi linier sederhana adalah membangun model matematis yang mampu memprediksi nilai suatu variabel berdasarkan variabel lain yang memiliki hubungan linear dengannya.

a. **Regresi linier sederhana** adalah metode analisis data yang bertujuan untuk menentukan hubungan antara satu variabel bebas (X) dan satu variabel terkait (Y), dengan regresi linier sederhana seperti :

- Memperkirakan nilai Y berdasarkan X.

Contoh : memperkirakan pendapatan seseorang berdasarkan jumlah jam kerja.

- Mengetahui seberapa kuat pengaruh variabel X terhadap Y.

Contoh : semakin linear dan konsisten hubungan keduanya, semakin akurat modelnya.

- Mencari garis terbaik (best fit line) garis ini digunakan untuk meminimalkan selisih antara nilai prediksi dan nilai sebenarnya.

5. Jelaskan secara singkat bagaimana cara kerja Decision Tree untuk menentukan suatu keputusan.

Jawab :

a. **Decision Tree** adalah metode analisis data dan machine learning yang bekerja dengan membagi data secara bertahap berdasarkan kondisi tertentu hingga menghasilkan suatu keputusan.

b. Cara kerja Decision Tree :

- Mulai dari akar (root node)

Model memilih atribut (fitur) terbaik yang paling dapat memisahkan data. Pemilihan fitur biasanya berdasarkan ukuran seperti **Gini Index**, **Entropy**, atau **Information Gain**.

- Membagi data berdasarkan kondisi fitur

Data dipisahkan menjadi cabang-cabang (branch) berdasarkan nilai fitur tersebut. Contoh : jika usia > 25 (cabang kanan) dan jika usia ≤ 25 (cabang kiri).

- Proses pembagian berulang setiap cabang akan diuji kembali dengan fitur lain hingga tidak ada fitur yang tersisa, data sudah homogen, dan batas kedalam tercapai.
- Membentuk node keputusan akhir (leaf node) setiap leaf berisi hasil keputusan, seperti :
“Lulus”
“Tidak Lulus”

Decision Tree menentukan keputusan dengan memilah data secara bertingkat berdasarkan fitur terbaik, sampai setiap node terakhir menghasilkan keputusan yang jelas.

6. Sebutkan dua kelebihan dan dua kekurangan algoritma Decision Tree.

Jawab :

a. Kelebihan Decision Tree

- Mudah dipahami dan diinterpretasikan, Struktur pohon keputusan mirip seperti aturan IF–THEN, sehingga hasil analisis sangat mudah dibaca, bahkan oleh orang non-teknis.
- Tidak perlu asumsi statistic, Decision Tree tidak membutuhkan asumsi seperti sebaran normal atau hubungan linear, Cocok untuk data kategori maupun numerik.


b. Kekurangan Decision Tree

- Rentan terhadap overfitting Jika tidak diatur batas kedalaman atau jumlah node, model bisa terlalu “hafal data” dan tidak general untuk data baru.
- Sensitif terhadap perubahan data, Perubahan kecil pada dataset dapat menghasilkan struktur pohon yang sangat berbeda, karena pemilihan fitur bergantung pada pembagian data saat training.

7. Berikan contoh sederhana penggunaan Decision Tree dalam kehidupan sehari-hari.

Jawab :

- Seorang siswa ingin memutuskan apakah dia perlu membawa payung sebelum berangkat sekolah



Decision Tree ini membantu siswa mengambil keputusan berdasarkan:

- Pengamatan kondisi langit.
- Informasi perkiraan cuaca.