

“LAPORAN UJIAN TENGAH SEMESTER”
MATA KULIAH BIG DATA PREDICTIVE



Disusun Oleh:

Erdhien Nizar Tharegi 23.01.5076

Kelas Perkuliahan : 23-D3 TI 03

Program Studi Teknik Informatika
Fakultas Ilmu Komputer
Universitas Amikom Yogyakarta
2025

1. **Jelaskan apa yang dimaksud dengan Big Data dan sebutkan empat karakteristik utamanya? (SCPMK 2, Bobot 10)**

Big Data adalah kumpulan data yang sangat besar, cepat berubah, dan beragam jenisnya, sehingga tidak bisa dikelola dengan cara pemrosesan data biasa. Untuk menyimpan, memproses, dan menganalisis data tersebut, diperlukan teknologi khusus.

Empat karakteristik utama (4V):

- **Volume** – ukuran data yang sangat besar (terabyte hingga petabyte).
- **Velocity** – kecepatan data dihasilkan dan diproses (real-time atau streaming).
- **Variety** – jenis data beragam: teks, gambar, video, sensor, log, dll.
- **Veracity** – tingkat kebenaran atau kualitas data (data bisa tidak lengkap, noise, atau tidak valid).

2. **Berikan contoh penerapan Big Data Predictive dalam bidang bisnis atau teknologi yang kamu ketahui? (SCPMK 2, Bobot 15)**

- **E-commerce (Shopee, Tokopedia)**
 - Memprediksi produk apa yang paling mungkin dibeli pelanggan berdasarkan riwayat pencarian, keranjang, dan pembelian sebelumnya. Hasilnya digunakan untuk menampilkan **rekomendasi produk personal**.
- **Perbankan**
 - Menggunakan data transaksi untuk **memprediksi potensi fraud** (penipuan) dengan mendeteksi pola transaksi yang tidak biasa.
- **Transportasi online (Gojek/Grab)**
 - Memprediksi **peak hour**, permintaan perjalanan, dan menentukan **dynamic pricing** (harga naik saat permintaan tinggi).

3. **Diberikan dataset sederhana dengan kolom berikut: ["Nama", "Usia", "Pendapatan", "Status"] Sebagian data memiliki nilai kosong (missing value) dan ada duplikasi baris.**

a. Jelaskan langkah-langkah yang kamu lakukan untuk membersihkan data tersebut.

a. Langkah-langkah membersihkan data:

1. Memeriksa missing value
 - Menggunakan fungsi seperti `isnull()` atau `info()` untuk melihat kolom mana yang kosong.
2. Menangani missing value
 - Untuk kolom numerik seperti Pendapatan, dapat diisi menggunakan mean (rata-rata).
 - Kolom lain misalnya Status bisa diisi menggunakan mode (nilai paling sering muncul) jika diperlukan.

3. Menghapus data duplikasi
 - Menggunakan fungsi `drop_duplicates()` untuk menghapus baris yang sama persis.
4. Memeriksa konsistensi tipe data
 - Memastikan Usia dan Pendapatan bertipe numerik, Nama dan Status bertipe string.
5. Normalisasi atau standarisasi (opsional)
 - Jika data akan digunakan untuk machine learning.

b. Tuliskan contoh potongan kode Python untuk menghapus duplikasi dan mengganti nilai kosong dengan rata-rata pendapatan. (SCPMK 3, Bobot 25)

```
import pandas as pd

# Contoh DataFrame
df = pd.DataFrame({
    "Nama": ["A", "B", "C", "C"],
    "Usia": [25, 30, None, 22],
    "Pendapatan": [4000000, None, 5000000, 5000000],
    "Status": ["Aktif", "Non-Aktif", "Aktif", "Aktif"]
})

# 1. Menghapus duplikasi
df = df.drop_duplicates()

# 2. Mengisi missing value kolom Pendapatan dengan rata-rata
mean_pendapatan = df["Pendapatan"].mean()
df["Pendapatan"].fillna(mean_pendapatan, inplace=True)
```

Penjelasan:

- `drop_duplicates()` → menghapus baris ganda.
- `fillna(mean_pendapatan)` → mengisi nilai kosong dengan rata-rata.

4. **Apa tujuan dari regresi linier sederhana dalam analisis data? (SCPMK 4, bobot 15)**

Tujuan **regresi linier sederhana** adalah untuk:

- **Memprediksi** nilai suatu variabel berdasarkan hubungan linier dengan satu variabel lain.
- **Menentukan seberapa kuat pengaruh** variabel bebas (X) terhadap variabel terikat (Y).
- **Menemukan garis terbaik** yang menggambarkan pola hubungan data.

Contoh: memprediksi pendapatan berdasarkan usia atau pengalaman kerja.

5. **Jelaskan secara singkat bagaimana cara kerja Decision Tree untuk menentukan suatu keputusan. (SCPMK 4, bobot 10)**

Cara kerja Decision Tree:

1. Data dianalisis untuk memilih atribut terbaik yang dapat memisahkan data (menggunakan Gini Index, Entropy, atau Information Gain).
2. Atribut tersebut dijadikan node/percabangan.
3. Data dibagi ke dalam cabang-cabang berdasarkan nilai atribut tersebut.
4. Proses berlanjut secara rekursif hingga:
 - semua data pada cabang homogen (kelas sama), atau
 - batas kedalaman terpenuhi.
5. Hasil akhirnya adalah leaf/daun yang berisi keputusan atau label.

6. **Sebutkan dua kelebihan dan dua kekurangan algoritma Decision Tree. (SCPMK 4, bobot 10)**

Kelebihan:

1. Mudah dipahami (visual dan menyerupai cara manusia berpikir).
2. Tidak butuh normalisasi data (bisa menangani data numerik dan kategorik).

Kekurangan:

1. Mudah mengalami overfitting jika tidak dikontrol kedalamannya.
2. Sensitif terhadap data yang berubah — sedikit perubahan bisa menghasilkan pohon yang berbeda.

7. Berikan contoh sederhana penggunaan Decision Tree dalam kehidupan sehari-hari. (SCPMK 4, bobot 15)

Contoh: Menentukan apakah seseorang pergi berolahraga atau tidak.

Decision Tree:

- Cuaca cerah?
 - Ya → Apakah suhu nyaman?
 - Ya → *Pergi olahraga*
 - Tidak → *Tidak olahraga*
 - Tidak → *Tidak olahraga*