

“LAPORAN UJIAN TENGAH SEMESTER”
MATA KULIAH BIG DATA PREDICTIVE



Disusun Oleh:

Erdhien Nizar Tharegi 23.01.5076

Kelas Perkuliahan : 23-D3 TI 03

Program Studi Teknik Informatika
Fakultas Ilmu Komputer
Universitas Amikom Yogyakarta
2025

1. Jelaskan apa yang dimaksud dengan Big Data dan sebutkan empat karakteristik utamanya? (SCPMK 2, Bobot 10)

Big Data adalah kumpulan data yang sangat besar, cepat berubah, dan beragam jenisnya, sehingga tidak bisa dikelola dengan cara pemrosesan data biasa. Untuk menyimpan, memproses, dan menganalisis data tersebut, diperlukan teknologi khusus.

Empat karakteristik utama (4V):

- **Volume** – ukuran data yang sangat besar (terabyte hingga petabyte).
- **Velocity** – kecepatan data dihasilkan dan diproses (real-time atau streaming).
- **Variety** – jenis data beragam: teks, gambar, video, sensor, log, dll.
- **Veracity** – tingkat kebenaran atau kualitas data (data bisa tidak lengkap, noise, atau tidak valid).

2. Berikan contoh penerapan Big Data Predictive dalam bidang bisnis atau teknologi yang kamu ketahui? (SCPMK 2, Bobot 15)

a. Marketplace (Tokopedia, Shopee)

Perusahaan menggunakan analisis prediktif untuk memperkirakan preferensi pelanggan, memberikan rekomendasi produk, serta menentukan strategi promosi yang sesuai dengan kebiasaan pengguna.

b. Industri manufaktur

Menerapkan prediksi kerusakan mesin melalui data sensor sehingga perawatan bisa dilakukan lebih cepat dan mengurangi risiko berhentinya proses produksi.

c. Transportasi digital (Gojek, Grab)

Data digunakan untuk memprediksi pola permintaan, estimasi waktu kesibukan, serta menetapkan tarif dinamis dalam kondisi tertentu.

d. Bisnis retail

Menggunakan model prediksi untuk menyusun perencanaan stok, memproyeksikan tren pembelian, dan memahami pola perilaku pelanggan.

e. Perbankan

Menggunakan data transaksi untuk memprediksi potensi fraud (penipuan) dengan mendeteksi pola transaksi yang tidak biasa.

3. Diberikan dataset sederhana dengan kolom berikut: ["Nama", "Usia", "Pendapatan", "Status"] Sebagian data memiliki nilai kosong (missing value) dan ada duplikasi baris.

- Impor data ke python menggunakan library pandas

```
import pandas as pd

# Contoh DataFrame
data = {
    "Nama": ["Erdhien", "Nizar", "Tharegi", "Erdhien", "Erdhiennizar"],
    "Usia": [25, 30, None, 25, 24],
    "Pendapatan": [4000000, None, 5000000, 4000000, None],
    "Status": ["Aktif", "Non-Aktif", "Aktif", "Aktif", "Non-Aktif"]
}

df = pd.DataFrame(data)

print("=== DATA MENTAH ===")
print(df)
```

```
=== DATA MENTAH ===
   Nama  Usia  Pendapatan  Status
0  Erdhien  25.0    4000000.0   Aktif
1   Nizar  30.0         NaN Non-Aktif
2  Tharegi   NaN    5000000.0   Aktif
3  Erdhien  25.0    4000000.0   Aktif
4 Erdhiennizar  24.0         NaN Non-Aktif
```

a. Jelaskan langkah-langkah yang kamu lakukan untuk membersihkan data tersebut.

- Identifikasi nilai yang hilang dilakukan dengan menampilkan data mentah terlebih dahulu menggunakan `print(df)`. Dari hasil tampilan tersebut terlihat bahwa beberapa kolom memiliki nilai kosong (NaN), seperti kolom "Pendapatan" dan "Usia". Dengan demikian, proses identifikasi missing value dilakukan secara langsung melalui output DataFrame sebelum pembersihan dilakukan.
- Mengisi missing value
 - Kolom numerik (misalnya Pendapatan atau Usia) dapat diisi dengan nilai mean.
 - Kolom kategori seperti Status dapat diisi nilai yang paling sering muncul (mode).
- Menghapus data duplikat
Menggunakan `drop_duplicates()` untuk memastikan tidak ada baris yang sama persis.
- Memastikan tipe data sesuai
kolom numerik harus bertipe int/float, kolom teks seharusnya string.
- Melakukan pengecekan akhir
Untuk memastikan dataset sudah tidak memiliki duplikasi dan nilai kosong.

b. Tuliskan contoh potongan kode Python untuk menghapus duplikasi dan mengganti nilai kosong dengan rata-rata pendapatan. (SCPMK 3, Bobot 25)

- Menggunakan **drop_duplicates()** untuk menghapus data duplikat dan memastikan tidak ada baris yang sama persis.

```
# Menghapus duplikasi
df = df.drop_duplicates()

print("=== HAPUS DUPLIKAT ===")
print(df)
```

```
=== HAPUS DUPLIKAT ===
```

	Nama	Usia	Pendapatan	Status
0	Erdhien	25.000000	4000000.0	Aktif
1	Nizar	30.000000	4500000.0	Non-Aktif
2	Tharegi	26.333333	5000000.0	Aktif
4	Erdhiennizar	24.000000	4500000.0	Non-Aktif

- Mengisi missing value pendapatan dengan rata-rata pendapatan menggunakan **fillna(mean_pendapatan)**

```
# Missing value
rata_pendapatan = df["Pendapatan"].mean()
df["Pendapatan"] = df["Pendapatan"].fillna(rata_pendapatan)

print("=== MENGISI NILAI KOSONG PENDAPATAN MENGGANTI DENGAN RATA-RATA PENDAPATAN ===")
print(df)
```

```
=== MENGISI NILAI KOSONG PENDAPATAN MENGGANTI DENGAN RATA-RATA PENDAPATAN ===
```

	Nama	Usia	Pendapatan	Status
0	Erdhien	25.000000	4000000.0	Aktif
1	Nizar	30.000000	4500000.0	Non-Aktif
2	Tharegi	26.333333	5000000.0	Aktif
4	Erdhiennizar	24.000000	4500000.0	Non-Aktif

- Mengisi missing value usia dengan rata-rata usia menggunakan **fillna(mean_usia)**

```
# Missing value
mean_usia = df["Usia"].mean()
df["Usia"] = df["Usia"].fillna(mean_usia)

print("=== MENGISI NILAI KOSONG USIA MENGGANTI DENGAN RATA-RATA USIA ===")
print(df)
```

```
=== MENGISI NILAI KOSONG USIA MENGGANTI DENGAN RATA-RATA USIA ===
```

	Nama	Usia	Pendapatan	Status
0	Erdhien	25.000000	4000000.0	Aktif
1	Nizar	30.000000	4500000.0	Non-Aktif
2	Tharegi	26.333333	5000000.0	Aktif
4	Erdhiennizar	24.000000	4500000.0	Non-Aktif

- Memastikan dataset sudah tidak memiliki duplikasi dan nilai kosong.

```
# Data Akhir
print("=== DATA AKHIR ===")
print(df)
```

```
=== DATA AKHIR ===
```

	Nama	Usia	Pendapatan	Status
0	Erdhien	25.000000	4000000.0	Aktif
1	Nizar	30.000000	4500000.0	Non-Aktif
2	Tharegi	26.333333	5000000.0	Aktif
4	Erdhiennizar	24.000000	4500000.0	Non-Aktif

4. Apa tujuan dari regresi linier sederhana dalam analisis data? (SCPMK 4, bobot 15)

Regresi linier sederhana digunakan untuk menganalisis hubungan antara satu variabel bebas (X) dan satu variabel terikat (Y). Tujuannya adalah:

- Memprediksi nilai variabel Y berdasarkan nilai variabel X.
- Mengetahui seberapa besar pengaruh X terhadap Y.
- Menyusun garis regresi yang mewakili pola hubungan antara dua variabel tersebut.

Contoh: memprediksi besar pengeluaran seseorang berdasarkan tingkat pendapatannya.

5. Jelaskan secara singkat bagaimana cara kerja Decision Tree untuk menentukan suatu keputusan. (SCPMK 4, bobot 10)

Decision Tree merupakan teknik dalam analisis data dan machine learning yang memproses data dengan membaginya ke dalam beberapa tahapan atau percabangan berdasarkan aturan tertentu, hingga akhirnya menghasilkan sebuah keputusan. Decision Tree bekerja dengan memecah data ke dalam beberapa cabang berdasarkan kondisi tertentu dari suatu fitur.

Cara Kerjanya:

- Memilih fitur yang paling efektif membagi data, menggunakan metode seperti Gini atau Entropy.
- Membuat percabangan berdasarkan nilai fitur tersebut.
- Setiap cabang kembali dianalisis untuk memilih fitur terbaik berikutnya.
- Proses berulang hingga data dalam cabang bersifat homogen atau batas kedalaman pohon tercapai.
- Node terakhir (leaf) akan berisi hasil keputusan atau label.

Decision Tree bekerja dengan membagi data secara berurutan menggunakan fitur yang paling relevan, hingga mencapai node akhir yang memberikan hasil keputusan yang pasti.

6. **Sebutkan dua kelebihan dan dua kekurangan algoritma Decision Tree. (SCPMK 4, bobot 10)**

Kelebihan:

1. Mudah dipahami karena menyerupai cara manusia berpikir.
2. Tidak butuh normalisasi data dapat digunakan untuk data numerik maupun kategorial.


Kekurangan:

1. Mudah mengalami overfitting jika tidak dikontrol kedalamannya dan percabangannya.
2. Sensitif terhadap data yang berubah, sedikit perubahan bisa menghasilkan pohon yang berbeda.

7. **Berikan contoh sederhana penggunaan Decision Tree dalam kehidupan sehari-hari. (SCPMK 4, bobot 15)**

Contoh: Menentukan apakah seseorang akan pergi bermain atau tidak.

Decision Tree:



Struktur Decision Tree:

- **Akar:** Cuaca bagus? — faktor utama yang langsung menentukan arah keputusan.
- **Cabang kiri (Cuaca = Tidak bagus):** Langsung menuju keputusan **Tidak Keluar**.
- **Cabang kanan (Cuaca = Bagus):** Lanjut ke pengecekan kedua — Ada waktu luang?

- Jika **Tidak** → keputusan **Tidak Keluar**.
- Jika **Ya** → keputusan **Keluar Bermain**.